Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»



Лабораторная работа №3 по дисциплине «Методы машинного обучения»


Выполнил: студент группы ИУ5-22М


Лю Ченхао

1. Цель лабораторной работы

изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей.


2. Основная часть





3. масштабирование признаков (не менее чем тремя способами)

```
data['standardized_n'] = preproc.StandardScaler().fit_transform(data[['age']])
data['minmax_n'] = preproc.minmax_scale(data[['age']])
data['l2_normalized_n'] = preproc.normalize(data[['age']], axis = 0)
fig, (ax1, ax2, ax3, ax4) = plt.subplots(4, 1, figsize = (7, 12))
plt.subplots_adjust(wspace =0, hspace =0.5)
ax1.hist(data['age'], bins = 100, color = 'g')
ax1.set_xlabel('')
ax1.set_ylabel('glucose')
ax1.set_title('original data')
ax2.hist(data['standardized_n'], bins = 100, color = 'g')
ax2.set_xlabel('')
ax2.set_ylabel('glucose')
ax2.set_title('standardized')
ax3.hist(data['minmax_n'], bins = 100, color = 'g')
ax3.set_xlabel('')
ax3.set_ylabel('glucose')
ax3.set_title('min-max')
ax4.hist(data['l2_normalized_n'], bins = 100, color = 'g')
ax4.set_xlabel('')
ax4.set_ylabel('glucose')
ax4.set_title('L2-normailzation')
```



4. обработку выбросов для числовых признаков (по одному способу для удаления выбросов и для замены выбросов);

```
u = data['age'].mean()
std = data['age'].std()
error = data[np.abs(data['age'] - u) > 3*std]
data_c = data[np.abs(data['age'] - u) <= 3*std]</pre>
print(data_c.head())
print(error.head())
    age marital education default balance housing loan
                                                      duration \
   58 married tertiary
                                     2143
                                             yes
                                                           261
 1 44 single secondary
                                       29
                                             yes no
                                                           151
                              no
 2 33 married secondary
                                             yes yes
 3 47 married unknown
                                     1506
                                             yes no
                                                            92
 4 33 single unknown
                              no
                                              no
                                                           198
    standardized_n minmax_n l2_normalized_n
         1.606965 0.519481
                                  0.006450
         0.288529 0.337662
                                  0.004893
        -0.747384 0.194805
                                  0.003670
```

5. обработку по крайней мере одного нестандартного признака (который не является числовым или категориальным);

```
from sklearn.preprocessing import LabelEncoder

gle = LabelEncoder()
genre_labels = gle.fit_transform(data['education'])
genre_mappings = {index: label for index, label in enumerate(gle.classes_)}
genre_mappings
Executed at 2024.06.06 21:57:28 in 22ms

{0: 0, 1: 1, 2: 2, 3: 3}
```

6. отбор признаков:

6.1один метод из группы методов фильтрации (filter methods);

```
#Filter
from sklearn.feature_selection import VarianceThreshold
selector = VarianceThreshold(threshold=3)
x_selected = selector.fit_transform(x)
print('Selected X Shape: ', x_selected.shape)
Executed at 2024.06.06 21:10:22 in 14ms
```

6.2один метод из группы методов обертывания (wrapper methods);

```
#Wrapper
from imblearn.over_sampling import BorderlineSMOTE
from sklearn.feature_selection import RFE, SelectFromModel
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
features = ['age', 'marital',
 'education',
 'default',
 'balance',
 'housing',
label = ['duration']
X_1 = data[features]
y_1 = data[label]
X_1.loc[:, 'age'] = X_1['age'].fillna(28.74)
X_1.loc[:, 'marital'] = X_1['marital'].fillna(1)
print(X_1.head())
print(y_1.head())
print(y_1['duration'].value_counts())
```

6.3один метод из группы методов вложений (embedded methods).

Список литературы

- [1] Гапанюк Ю. Е. Лабораторная работа «Подготовка обучающей и тестовой выборки, кросс-валидация и подбор гиперпараметров на примере метода ближайших соседей» [Электронный ресурс] // GitHub. Режим доступа: https://github.com/ugapanyuk/ml_course/wiki/LAB_KNN.
- [2] Team The IPython Development. IPython 7.3.0 Documentation [Electronic resource] // Read the Docs.. Access mode: https://ipython.readthedocs.io/en/ stable/
- [3] Waskom M. seaborn 0.9.0 documentation [Electronic resource] // PyData.. —

Access mode: https://seaborn.pydata.org/.

[4] pandas 0.24.1 documentation [Electronic resource] // PyData.. — Access mode: http://pandas.pydata.org/pandas-docs/stable/.